LG 자율주행 안테나 경진대회

Team 해커톤

정재윤, Kade Na, 강보근

목차

해커톤 팀 역할분담

정재윤

파생변수 생성 및 모델 Search

Kade Na

모델 Search 및 hyperparameter tuning

강보근

데이터 분석 및 파생변수 생성

데이터 분석
&
파생변수 생성

데이터 분석

도메인 지식 및 아이디어 수집

파생변수 생성

데이터 Drop

데이터 분석

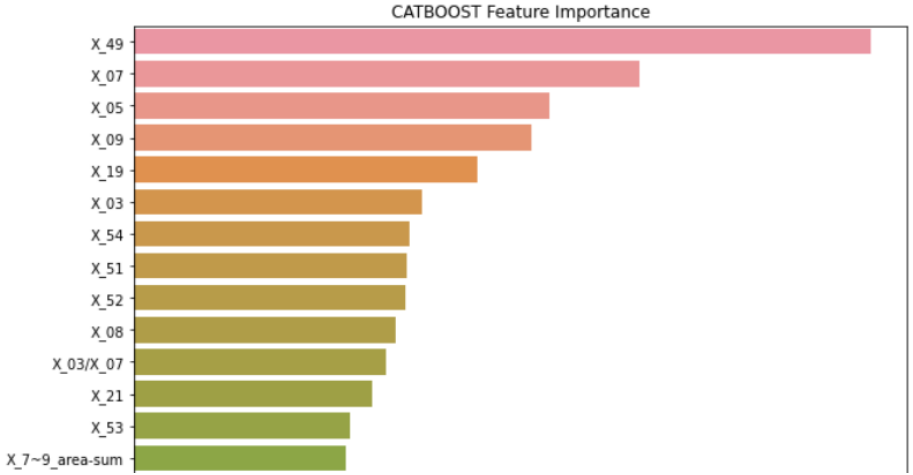

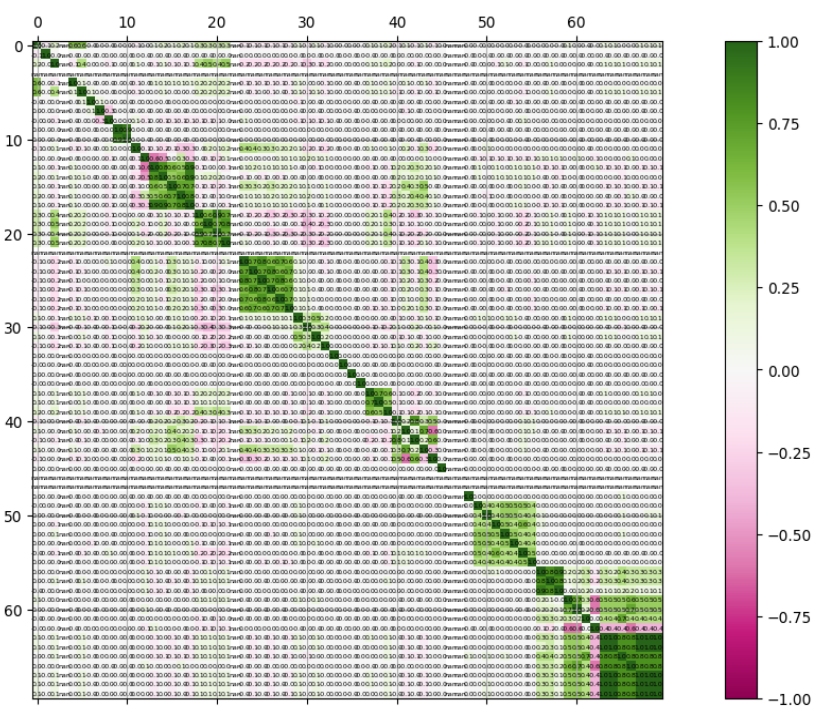

Catboost의 Feature Importance, X_value Heatmap 등의 분석을 사용해 전반적인 데이터를 분석함.

도메인 지식 및 아이디어 수집

그림 2: 왼쪽 그림은 "잘못된 배치"로 레이돔이 표면이 고르지 않고 안테나에 평행하게 배치되지 않았습니다. 오른쪽 그림은 "올바른 배치"로 레이돔의 거리가 균일할 뿐 아니라 배치와 크기가 올바릅니다. (이미지 출처: InnoSenT)

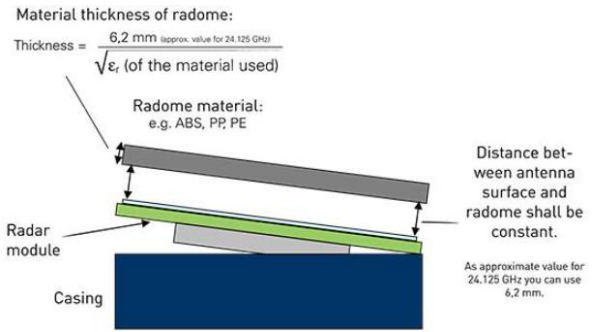

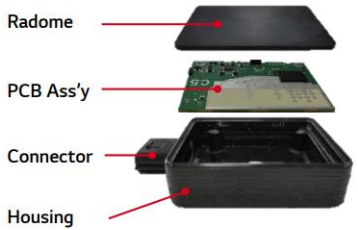

도메인 지식을 통한 데이터 이해를 위해 Radar 센서 제작 과정 및 주의사항에 대한 조사를 진행함.

레이돔의 거리 균일도에 따라서 전자기파의 분산과 결과물의 결과가 달라질 수 있다는 도메인 지식을 습득함.

=> X_41~X_44 diff 파생변수 생성

이 외에도 습득한 도메인 지식을 기반으로 파생변수를 생성해보거나, feature drop을 시도함.

파생변수 생성

1. X_03/X_07 (무게 / 면적)

무게 / 면적을 통해 방열 재료 1의 면적대비 무게를 구해 새로운 변수를 생성함. (2와 3은 무게의 데이터 부족)

2. X_41~X_44 diff

X_41~X_44중 max값과 min값을 찾아 max - min을 통해 레이돔 치수의 최대 차이에 대한 변수를 생성함.

3. X_01, 02, 05, 06 sum

단계별 누름량을 모두 더해 총 가해진 누름량에 대한 변수를 생성함.

4. X_07~09 sum

방열 재료의 면적을 모두 더해 총 방열재료의 면적에 대한 변수를 생성함

파생변수 생성

5. X_03/X_19~22

방열재료 무게 / 스크류 삽입 깊이의 합을 통해 무게와 관련된 스크류 삽입 깊이의 관계에 대한 변수를 생성함.

6. X_12 / X_24, X_25

커넥터 위치 좌표와 커넥터핀 치수의 관계를 알기 위해서 변수를 생성함.

7. X 49_7_19_3_8

Heatmap에서 importance가 높은 데이터들을 train 데이터의 평균값으로 나눈 합에 대한 변수를 생성함.

데이터 Drop

```
drop_list = ["X_04", "X_23", "X_47", "X_48"]
```

- X_04, X_23, X_47, X_48 변수는 검사 통과 여부에 대한 변수이며, 학습에 필요가 없기 때문에 제외함.

```
drop_x = ["X_02", "X_10","X_11", "X_34", "X_35", "X_36", "X_37","X_45"]
```

Catboost의 select_features함수를 사용했으며, RecursiveByShapValues 알고리즘 방법으로 Shap value기반 가장 중요도가 낮은 Feature들을 골라내서 한번 더 분석하고, Drop하였습니다.

- X_02, X_45 : select feature 함수에서 제거되었으며, Feature importance가 낮아 Drop함
- X_10, X_11 : NAN value가 너무 많아 복구하더라도 좋은 성능을 보이지 못해서 Drop함
- X_34~X_37 : 스크류 체결 시 분당 회전수는 select feature 함수에서 제거되었으며,

  Heatmap에서도 y_value와 유의미한 상관관계를 보이지 못해 Drop함

데이터 구축
&
모델 선정

Validation Set 구축 전략

- 6 Stratified Fold based on label

모델 선정

- Gradient Boosting-based ML Algorithms
  - CatBoost
  - LGBM
  - XGBoost
- Hyperparameter Tuning (optuna)
- 3 model ensemble

Validation Set 구축 전략

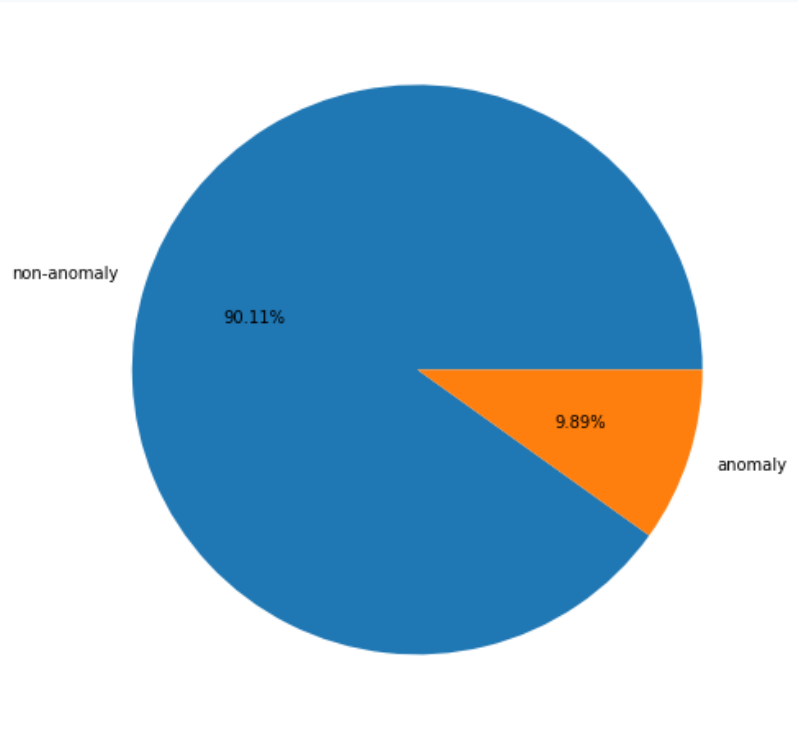

Train Dataset의 정상/불량 데이터의 분포를 보게 되면 불량에 해당하는 데이터는 전체 10%에 달합니다.

또한 Train Dataset의 개수가 39607개밖에 없으므로 전체 데이터를 사용해 모델이 적은 수의 데이터로도 잘 학습할 수 있도록 계획을 세워야 했습니다.

따라서 불량에 해당하는 데이터도 모델이 잘 학습할 수 있고, 데이터를 사용해 여러번 학습할 수 있도록 label 비율 Stratified KFold를 사용해 데이터셋 구축시 불량 label에 대한 비율을 강제하고, 여러번 학습할 수 있도록 했습니다.

CatBoost(Categorical Boosting)

- An algorithm for gradient boosting on decision trees
- Ordered boosting
- Uses a breadth-first search algorithm to create trees(**level-wise**)

Advantages

1. Great quality without parameter tuning
2. Improved accuracy

LGBM(Light GBM)

- A gradient boosting framework that uses tree based learning algorithms
- Utilizes **leaf-wise** algorithm on the tree (Memory and time efficiency with a deeper tree)

Advantages

1. Faster training speed and higher efficiency.
2. Lower memory usage.
3. Better accuracy.
4. Support of parallel, distributed, and GPU learning.
5. Capable of handling large-scale data.

XGBoost

- An optimized distributed gradient boosting library designed to be highly efficient, flexible and portable
- Gradient Boosting Machine + Optimization(Tuned Hyperparameters) + Algorithm
- Regularization to avoid overfitting
- Built-in Cross Validation
- Parallelisation
- Cache Optimization

Advantages

1. Better accuracy.
2. Support of parallel, distributed, and GPU learning.
3. It Works well in small to medium dataset

HyperParameter Tuning (optuna)

- For hyperparameter tuning, we used **Optuna**, an automatic hyperparameter optimization software framework
- By setting: (for xgb)
  - random_state
  - a range of learning_rate
  - n_estimators
  - a range of max_depth
  - a range of subsample
  - a range of colsample_bytree
- Multiple trials were ran to find the best/minimum value with the hyperparameters
- For algorithm, we use **TPESampler** (Sampler using Tree-structured Parzen Estimator)

Output Example

- [I 2022-08-10 14:07:34,663] Trial 23 finished with value: 1.941010155721771 and parameters: {'learning_rate': 0.006010848429163341, 'max_depth': 8, 'subsample': 0.7921365050833529, 'colsample_bytree': 0.8569759398897375}. Best is trial 23 with value: 1.941010155721771.

- [I 2022-08-10 00:53:46,864] Trial 31 finished with value: 1.9409859593627379 and parameters: {'learning_rate': 0.006139295456352811, 'max_depth': 8, 'subsample': 0.7555884047040881, 'colsample_bytree': 0.8638977924043896}. Best is trial 31 with value: 1.9409859593627379.

3 model ensemble

Use Ensemble for

- Higher accuracy
- Reduce the single-model error
- Maintaining the model's generalization

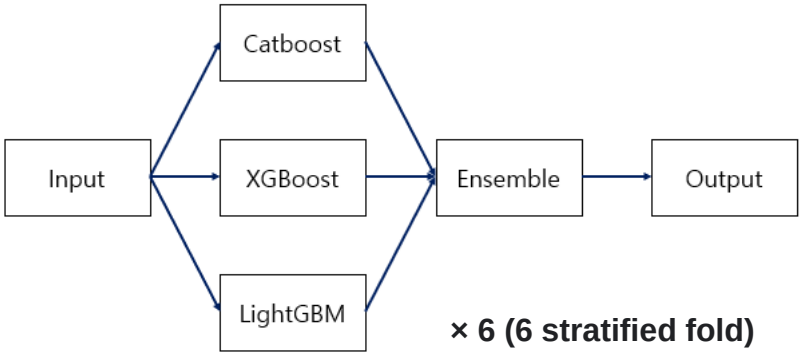

- Use two different tree growing policy
  - Levelwise - Catboost, Xgboost
  - Leafwise - LightGBM

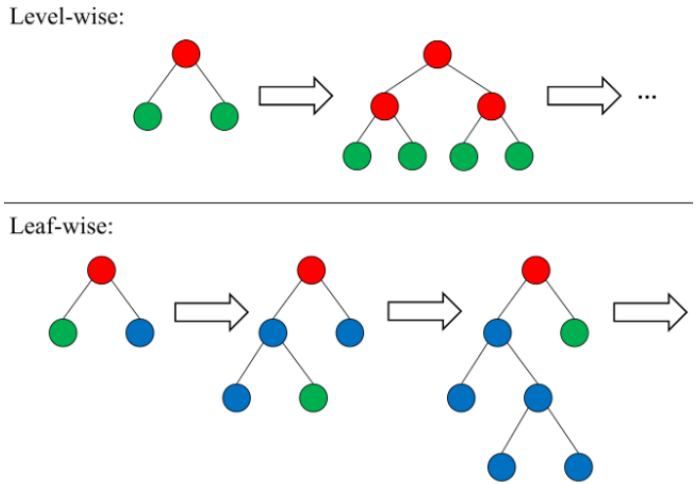

THANK YOU TO ALL!

Any Questions?